

Positionspapier zum Einsatz von KI-Detektoren im Hochschulkontext

Der AStA lehnt den Einsatz von KI-Detektoren in schriftlichen Arbeiten ab und fordert stattdessen eine einheitliche fachliche Überprüfung.

1 Ausgangslage

Die rasche Verbreitung generativer KI-Werkzeuge verändert die Anforderungsprofile in Studium, Prüfung und Beruf grundlegend. Schriftliche Leistungsnachweise lassen sich je nach Aufgabenstellung teilweise oder vollständig automatisiert erstellen, ohne dass sich dies zuverlässig nachweisen ließe. Zugleich wächst die Erwartung, Studierende auf eine Arbeitswelt vorzubereiten, in der KI-gestützte Werkzeuge zum Alltag gehören, ohne dass fachliche Urteilsfähigkeit, Eigenverantwortung und kritischer Umgang mit Quellen an Bedeutung verliert.

Die DHBW steht damit vor einer doppelten Aufgabe: Sie muss die akademische Integrität sichern und zugleich die berufliche Befähigung ihrer Studierenden weiterentwickeln. Dazu gehören praktische KI-Kompetenz, der reflektierte Umgang mit Medien und Quellen, die Sensibilität für Bias in KI-Systemen sowie ein Bewusstsein für den erheblichen Ressourcenverbrauch dieser Technologien.

Der AStA plädiert ausdrücklich nicht für die Abschaffung schriftlicher Leistungen. Stattdessen soll bei schriftlichen Prüfungsleistungen, bei denen eine unzulässige Nutzung generativer KI grundsätzlich möglich ist, eine kurze mündliche Abfrage standardmäßig in das jeweilige Modul integriert werden. Ergänzend fordert der AStA DHBW-einheitliche und klar kommunizierte prüfungsrechtliche Regelungen, insbesondere für Haus-, Praxis- und Studienarbeiten.

2 Position des AStA in Kürze

Der AStA lehnt den Einsatz von KI-Detektoren im Prüfungskontext ab. Diese Ablehnung ist eindeutig und nicht auf einzelne Anwendungsfälle beschränkt und begründet sich aus den folgenden Aspekten:

- **Untauglich für Prüfungsentscheidungen.** Detektoren liefern ausschließlich Wahrscheinlichkeiten ohne Beweischarakter und dürfen über Täuschungsvorwürfe nicht entscheiden. Weder allein noch als „unterstützendes“ Indiz.
- **Unzuverlässig und verzerrt.** Detektoren sind leicht zu umgehen und benachteiligen systematisch bestimmte Gruppen. Ihre Fehler treffen gerade integre und nicht-muttersprachliche Studierende.
- **Datenschutzrechtlich unverantwortlich.** Externe Detektionsdienste verarbeiten personenbezogene Daten häufig intransparent und in Drittstaaten ohne klare Rechtsgrundlage.

Solange diese strukturellen Probleme bestehen, ist für den AStA kein verantwortbarer Einsatz von KI-Detektoren erkennbar. Die richtige Antwort auf generative KI ist nicht eine bessere Überwachungstechnologie, sondern eine kompetenzorientierte Prüfungsgestaltung.

3 Gründe für die Ablehnung von KI-Detektoren

3.1 Funktionsweise von KI-Detektoren

Um die Problematik von KI-Detektoren genauer beleuchten zu können, muss zu Beginn die Funktionsweise dieser erläutert werden. Im Gegensatz zu menschlichen Lesern analysieren KI-Detektoren Texte nicht auf den inhaltlichen Sinn, sondern auf statistische Muster. Dabei stützen sich Detektoren auf Metriken wie die Perplexität, d.h. die Vorhersagbarkeit der Wortwahl, und die Burstiness, d.h. die Varianz der Satzlänge und -komplexität [1]. Da große Sprachmodelle (engl. Large Language Models, LLMs) den statistisch wahrscheinlichsten nächsten Baustein, ein sog. Token, vorhersagen, produzieren LLMs Texte mit geringer Perplexität und Burstiness. Ein KI-Detektor klassifiziert dementsprechend Texte mit großer Vorhersagbarkeit der Wortwahl, d.h. niedriger Perplexität, und niedriger Burstiness, d.h. Sätze in gleichmäßiger Länge und identischer Struktur, als KI-generiert.

3.2 Geringe Genauigkeit und Fehlklassifikationen

Diese statistische Klassifikation ist fehleranfällig, da sie ausschließlich auf Wahrscheinlichkeiten beruht. Wird ein von Menschen verfasster Text als KI-generiert eingestuft, spricht man von einem sog. False Positive.

Ein bekanntes Beispiel ist die Einordnung der Verfassung der Vereinigten Staaten von Amerika als KI-generiert. Dabei wirken zwei Effekte zusammen: Zum einen handelt es sich um ein juristisches Dokument mit präzisen, formelhaften Formulierungen und geringer sprachlicher Varianz. Zum anderen ist der Text nach Angaben des GPTZero-Entwicklers Edward Tian in den Trainingsdaten vieler Sprachmodelle stark überrepräsentiert, sodass diese Modelle darauf trainiert sind, ähnliche Texte zu erzeugen [2]. Der Detektor erkennt in diesem Fall also gewissermaßen sein eigenes Vorbild wieder.

Dass es sich nicht um Einzelfälle handelt, zeigen systematische Untersuchungen. Eine internationale Studie, die verbreitete Detektionswerkzeuge unter kontrollierten Bedingungen getestet hat, kam zu dem Ergebnis, dass keines von ihnen zuverlässig zwischen menschlichen und KI-generierten Texten unterscheidet [3]. Selbst große Anbieter empfehlen ihre eigenen Klassifikatoren nicht mehr: OpenAI stellte den eigenen Detektor am 20. Juli 2023 wegen zu geringer Trefferquote ein. Bereits in der herstellereigenen Evaluation bei Veröffentlichung des Werkzeugs wurden nur rund ein Viertel der KI-Texte korrekt erkannt, während fast jeder zehnte menschliche Text fälschlich als KI eingestuft wurde [4].

Hinzu kommt ein verbreiteter Denkfehler im Umgang mit Fehlerquoten. Aus einer angegebenen Falsch-Positiv-Rate von einem Prozent folgt gerade nicht, dass ein markierter Text mit 99-prozentiger Wahrscheinlichkeit KI-generiert ist. Diese Wahrscheinlichkeit hängt zusätzlich von der Basisrate ab, also vom tatsächlichen Anteil KI-generierter Arbeiten im geprüften Jahrgang – und dieser Anteil ist in der Praxis grundsätzlich unbekannt [5]. Ein Detektionswert lässt sich damit nicht sinnvoll in eine Aussage über den Einzelfall übersetzen.

Solche Fehlklassifikationen erzeugen zudem einen „Chilling Effect“: Schreibende geraten unter Generalverdacht und richten ihr Schreiben defensiv an vermeintlich unverdächtigen Formulierungen aus, was Leistungsbereitschaft und gestalterische Freiheit beeinträchtigt [6].

3.3 Umgehbarkeit von KI-Detektoren

KI-Detektoren lassen sich mit geringem Aufwand umgehen. Bereits leichte Überarbeitungen, Paraphrasierungen oder der Umweg über eine maschinelle Übersetzung senken die Erkennungsrate deutlich [3]. Es existieren Werkzeuge, die genau darauf ausgelegt sind [7].

Daraus folgt ein Einwand, der die Abschreckungswirkung von Detektoren grundsätzlich in Frage stellt: Wer die Umgehung beherrscht, wird nicht erfasst. Detektoren messen deshalb weniger die unzulässige Nutzung generativer KI als vielmehr die fehlende Routine im Umgang mit ihr sowie den fehlenden Zugang zu leistungsfähigeren Werkzeugen [5]. Sie belasten damit systematisch die weniger versierten Studierenden, während sie gerade diejenigen nicht erreichen, auf die sie zielen.

3.4 Bias gegenüber Nicht-Muttersprachlern

Bei der Klassifikation von Texten von Nicht-Muttersprachlern kommt es zu systematischen Verzerrungen, sog. Bias. Eine Studie der Universität Stanford aus dem Jahr 2023 prüfte sieben verbreitete Detektoren an 91 TOEFL-Essays. Die Detektoren stuften im Durchschnitt über 61 % dieser Essays fälschlich als KI-generiert ein, während Texte muttersprachlicher Verfasser nahezu fehlerfrei erkannt wurden [8].

Erklären lässt sich der Befund mit der Funktionsweise der Detektoren: Wer in einer Fremdsprache formuliert, verwendet tendenziell kürzere Sätze, einen kleineren Wortschatz und weniger komplexe Konstruktionen. Perplexität und Burstiness sinken – und genau das werten Detektoren als Hinweis auf KI.

Die Anbieter haben auf die Studie reagiert. GPTZero veröffentlichte 2023 ein überarbeitetes Modell und bezeichnete den Befund als überholt. Eine unabhängige Nachmessung an demselben Datensatz ergab für dieses überarbeitete Modell jedoch weiterhin eine Falsch-Positiv-Rate von 7,7 % [9]. Auch nach der Nachbesserung wird also etwa jeder dreizehnte Text zu Unrecht markiert. Für internationale duale Studierende sowie duale Studierende mit Migrationshintergrund wiegt das besonders schwer: Eine Fehlerquote, die sich nicht zufällig, sondern entlang der sprachlichen Herkunft verteilt, verstärkt bestehende Ungleichheiten und erzeugt reale Benachteiligungen.

3.5 Rechtliche Einordnung

Der Einsatz **externer** Detektionsdienste ist datenschutzrechtlich fragwürdig. Vor der Einführung von KI-Anwendungen, die personenbezogene oder studienrelevante Daten verarbeiten, sind klare Rechtsgrundlagen, definierte Verantwortlichkeiten und eine Datenschutz-Folgenabschätzung nach DSGVO Art. 35 erforderlich. Viele Dienste verarbeiten Texte in Rechenzentren außerhalb der EU, teils ohne transparenten Umgang mit Speicherung und Weiterverwendung. Damit setzen Hochschulen die Daten ihrer Studierenden und sich selbst rechtlichen Risiken aus. Hinzu kommt im Kontext der DHBW, dass Studienarbeiten häufig mit Sperrvermerken versehen sind, da unternehmensintern Daten verwendet werden. Ein Verstoß gegen einen solchen Sperrvermerk durch den Upload in einen externen Dienst setzt die DHBW einem rechtlichen Risiko und möglichen Klagen der dualen Partner aus.

Ebenfalls anzumerken ist, dass im deutschen Prüfungsrecht die Hochschule die Beweislast trägt. Bei einem Täuschungsvorwurf muss sie die Täuschung nachweisen. Da Detektionssoftware ausschließlich Wahrscheinlichkeiten liefert und keine Beweise im juristischen Sinn, ist sie als Grundlage für disziplinarische Maßnahmen nicht tragfähig. Ein Sanktionsverfahren auf einem Detektionswert aufzubauen, wäre rechtlich fragwürdig, angreifbar und gegenüber den Betroffenen unfair, denn ein Detektionswert ist kein Beweismittel und darf auch nicht als „unterstützendes“ Indiz in ein Täuschungsverfahren einfließen. Wer einem unzuverlässigen Wahrscheinlichkeitswert über den Umweg der freien Beweiswürdigung doch Gewicht verleiht, verlagert die Beweislast faktisch auf die Studierenden und unterläuft den Grundsatz fairer Prüfungen. Der AStA lehnt eine solche Verwendung ausdrücklich ab.

3.6 Position des AStA

Wir benennen den Effekt bewusst zweiseitig, denn eine glaubwürdige Integritätssicherung wirkt abschreckend auf Täuschungsversuche und ist ein legitimes Ziel. Der entscheidende Unterschied ist, dass diese Abschreckung nicht auf der Bestrafung Unschuldiger beruhen darf. Genau das aber riskiert ein Verfahren, das Fehlalarme zur Sanktionsgrundlage macht. Die Schwächen der KI-Detektion sind technischer, rechtlicher, ethischer und pädagogischer Natur. In ihrer Summe lassen sie sich nicht beheben, ohne das Verfahren selbst aufzugeben. Der AStA zieht daraus eine klare Konsequenz: **KI-Detektoren gehören nicht in den Prüfungskontext**. Das bedeutet nicht die Abschaffung schriftlicher Arbeiten, sondern den Verzicht auf eine untaugliche Überwachungstechnologie zugunsten einer unmittelbaren fachlichen Überprüfung der eingereichten Leistung.

Der naheliegende Vergleich mit Plagiatsoftware trägt die Detektoren gerade nicht, denn ein Plagiatbefund verweist auf eine konkrete, überprüfbare Quelle, die ein Mensch nachlesen und bestätigen kann. Ein KI-Detektor liefert dagegen nur eine Wahrscheinlichkeit ohne nachprüfbaren Beleg. Es gibt nichts, was sich gegenprüfen ließe. Was bei Plagiaten ein **überprüfbarer Hinweis** ist, bleibt bei KI-Detektoren eine **bloße Behauptung**. Der Vergleich rechtfertigt deshalb keinen Einsatz, sondern unterstreicht die Ablehnung.

4 Fachliche Klärung statt technischer Detektion

Bei schriftlichen Prüfungsleistungen, bei denen die Möglichkeit einer unzulässigen KI-Nutzung besteht, soll standardmäßig eine kurze mündliche Abfrage in das jeweilige Modul integriert werden. Dabei wird ausschließlich überprüft, ob die studierende Person die Inhalte ihrer Arbeit verstanden hat, zentrale Aussagen erläutern und fachliche Entscheidungen begründen kann.

Ziel ist nicht der Nachweis der Urheberschaft jedes einzelnen Satzes, sondern die Feststellung, ob eine nachvollziehbare eigenständige Auseinandersetzung mit dem Thema und den eingereichten Inhalten stattgefunden hat.

Enthält das Modul bereits eine mündliche Prüfung, kann diese Aufgabe durch den bestehenden Prüfungsteil übernommen werden. Andernfalls wird eine kurze mündliche Abfrage als zusätzlicher, verbindlicher Prüfungsbestandteil in das Modul aufgenommen. Eine umfassende Änderung der bestehenden Prüfungsformate ist dafür nicht erforderlich.

Die mündliche Abfrage wird nicht benotet, sondern ausschließlich mit „bestanden“ oder „nicht bestanden“ bewertet. Die Anforderungen und Bewertungskriterien müssen vorab transparent kommuniziert und für alle Studierenden einheitlich angewendet werden. Auf diese Weise wird die fachliche Auseinandersetzung unmittelbar überprüft, ohne auf unzuverlässige KI-Detektoren zurückzugreifen.

5 Position und Forderungen des AStA

Kernthese: Der AStA lehnt den Einsatz von KI-Detektoren in schriftlichen Arbeiten ab. Sie sind unzuverlässig, verzerrt, leicht umgehbar, datenschutzrechtlich bedenklich und ohne Beweischarakter.

5.1 Prinzipien

- **Fairness:** keine Bewertung oder Sanktion auf Basis unsicherer, verzerrter oder leicht täuschbarer Tools.

- **Transparenz:** klare Prüfungsformate mit vorab kommunizierten Kriterien und Rubriken sowie Einsicht in Protokolle.
- **Verhältnismäßigkeit:** Maßnahmen, die Integrität sichern, ohne Grundrechte zu gefährden, und die Kompetenzen angemessen überprüfen.
- **Inklusion:** aktive Unterstützung für Studierende, die in Prüfungssituationen besonders belastet sind – über alle Prüfungsformate hinweg.

5.2 Kernforderungen zum Prüfungswesen

- Kein Einsatz von KI-Detektoren als Grundlage für Prüfungs- oder Sanktionsentscheidungen. Bei schriftlichen Prüfungsleistungen, bei denen eine unzulässige Nutzung generativer KI grundsätzlich möglich ist, wird stattdessen standardmäßig eine kurze mündliche Abfrage für alle Studierenden in das jeweilige Modul integriert.
- DHBW-einheitliche, klar kommunizierte prüfungsrechtliche Regelungen in allen Prüfungsformen, insbesondere zur Nutzung von KI sowie für Haus-, Praxis- und Studienarbeiten.

6 Fazit

KI-Detektoren gehören nicht in den Prüfungskontext. Sie sind technisch unzuverlässig, leicht umgehbar, verzerrt zulasten bestimmter Studierendengruppen, datenschutzrechtlich bedenklich und besitzen keinen verlässlichen Beweischarakter. Der AStA lehnt ihren Einsatz daher ab.

Dies bedeutet nicht die Abschaffung schriftlicher Prüfungsleistungen. Bei Prüfungen, bei denen eine unzulässige Nutzung generativer KI grundsätzlich möglich ist, soll stattdessen standardmäßig eine kurze mündliche Abfrage für alle Studierenden in das jeweilige Modul integriert werden. Bestehende mündliche Prüfungsteile können diese Aufgabe übernehmen. Die Abfrage wird nicht benotet, sondern ausschließlich mit „bestanden“ oder „nicht bestanden“ bewertet.

7 Quellen

- [1] S. Gehrmann, H. Strobelt, und A. M. Rush, „GLTR: Statistical Detection and Visualization of Generated Text“, *arXiv*, 2019, doi: 10.48550/arXiv.1906.04043.
- [2] B. Edwards, „Why AI writing detectors don't work“. [Online]. Verfügbar unter: <https://arstechnica.com/information-technology/2023/07/why-ai-detectors-think-the-us-constitution-was-written-by-ai/>
- [3] D. Weber-Wulff und others, „Testing of detection tools for AI-generated text“, *International Journal for Educational Integrity*, Bd. 19, Nr. 1, S. 26, 2023, doi: 10.1007/s40979-023-00146-z.
- [4] OpenAI, „New AI classifier for indicating AI-written text“. [Online]. Verfügbar unter: <https://openai.com/index/new-ai-classifier-for-indicating-ai-written-text/>
- [5] M. A. Bassett und others, „Heads we win, tails you lose: AI detectors in education“, *Journal of Higher Education Policy and Management*, S. 1–16, 2026, doi: 10.1080/1360080X.2026.2622146.
- [6] L. Giray, K. Sevnanarayan, und F. Ranjbaran Madiseh, „Beyond Policing: AI Writing Detection Tools, Trust, Academic Integrity, and Their Implications for College Writing“, *Internet Reference Services Quarterly*, Bd. 29, Nr. 1, S. 83–116, 2025, doi: 10.1080/10875301.2024.2437174.
- [7] M. Perkins und others, „GenAI Detection Tools, Adversarial Techniques and Implications for Inclusivity in Higher Education“, *International Journal of Educational Technology in Higher Education*, Bd. 21, Nr. 1, S. 53, 2024, doi: 10.1186/s41239-024-00487-w.

- [8] W. Liang, M. Yuksekgonul, Y. Mao, E. Wu, und J. Zou, „GPT detectors are biased against non-native English writers“, *Patterns*, Bd. 4, Nr. 7, S. 100779, 2023, doi: [10.1016/j.patter.2023.100779](https://doi.org/10.1016/j.patter.2023.100779).
- [9] B. Emi und M. Spero, „Technical Report on the Pangram AI-Generated Text Classifier“, *arXiv*, 2024, doi: [10.48550/arXiv.2402.14873](https://doi.org/10.48550/arXiv.2402.14873).